

Raport Końcowy Projektu: Zaawansowane Sieci Neuronowe

Temat: Interpretowalność relacyjnych sieci grafowych (RGCN) w zadaniu przewidywania skutków ubocznych leków na grafie wiedzy Hetionet.

Autorzy: Jakub Jażdżyk, Kajetan Rożej

Data: 6.06.2026

Repozytorium: <https://github.com/kubajaz/XAI>

1. Wprowadzenie i kontekst

Współczesna medycyna i farmakologia operują na ogromnych grafach wiedzy łączących leki, geny, choroby i skutki uboczne. Modele grafowe potrafią wykorzystać te powiązania do predykcji brakujących relacji, lecz w zastosowaniach klinicznych i badawczych sama predykcja („lek X powoduje skutek Y”) jest niewystarczająca - potrzebne jest uzasadnienie w postaci ścieżek biologicznych wspierających decyzję modelu.

Niniejszy raport podsumowuje pracę opisaną we wstępnej dokumentacji. W trakcie implementacji **zadanie docelowe zostało zmienione** na relację **CcSE** (*Compound causes Side Effect*) zamiast pierwotnie planowanej relacji CtD (*Compound treats Disease*). W Hetionet v1.0 relacji CcSE jest **138 944**, a CtD tylko **755** - skupiliśmy się więc na predykcji i interpretacji skutków ubocznych, gdzie mamy dużo danych nadzorowanych i sensowne zadanie link prediction.

Problem badawczy: Jak skutecznie przewidzieć brakujące krawędzie CcSE na pełnym heterogenicznym grafie Hetionet oraz jak wyekstrahować z predykcji związane, wierne modelowi podgrafy wyjaśniające?

2. Cele, hipotezy i pytania badawcze

Celem projektu, zgodnie z założeniami przedstawionymi w raporcie wstępnym była implementacja relacyjnej sieci grafowej (RGCN), która nauczy się semantyki grafu wiedzy Hetionet, a następnie zostanie poddana procesowi interpretacji przy użyciu metod XAI (Explainable AI).

2.1. Hipotezy (do weryfikacji wynikami)

1. **H1 (Relacyjność):** Architektura RGCN, dzięki zastosowaniu osobnych macierzy wag dla każdego typu relacji, jest w stanie odróżnić krawędzie o

znaczeniu pozytywnym (terapeutycznym) od negatywnych (skutki uboczne).

Po zmianie zadania z CtD na CcSE (pkt. 1) weryfikujemy H1 operacyjnie: czy RGCN wykorzystuje heterogeniczne typy relacji Hetionet do skutecznej predykcji krawędzi CcSE.

2. **H2 (Redukcja Szumu):** Metoda GNNExplainer pozwoli na wyekstrahowanie z gęstego grafu (tzw. *hairball*) ścieżek o długości 2-3 skoków, które są zrozumiałe dla eksperta i biologicznie poprawne.

Odpowiedź na hipotezy: H1 - TAK · H2 - TAK

H1: We wstępnej dokumentacji planowaliśmy relację docelową **CtD** (*Compound treats Disease*). Po analizie danych **zmieniliśmy zadanie na CcSE** (*Compound causes Side Effect*) - w Hetionet jest znacznie więcej krawędzi CcSE niż CtD, więc link prediction i XAI sensownie wykonujemy na skutkach ubocznych. W tym ustawieniu RGCN z osobnymi wagami dla 24 typów relacji osiąga **test AP/AUC $\approx$ 0,95** na CcSE: model wykorzystuje więc relacyjną strukturę grafu do przewidywania relacji ubocznych. **H1 uznajemy za potwierdzoną** w zakresie przyjętego po pivotcie zadania (predykcja CcSE na pełnym Hetionet).

H2: maskowanie top-15 krawędzi obniża score z dodatnią fidelity; podgrafy wyjaśnienia są zwarte, ze ścieżkami 2-3-skokowymi od leku do skutku ubocznego.

3. Zbiór danych i preprocessing

3.1. Hetionet v1.0 (baseline)

Element	Wartość (z dokumentacji wstępnej / po wczytaniu grafu)
Węzły (łącznie)	47 031 (11 typów: Compound, Disease, Gene, ...)
Krawędzie (łącznie)	2 250 197 (24 typy relacji)
Relacja docelowa	CcSE - Compound $\rightarrow$ Side Effect
Liczba krawędzi CcSE	138 944
Liczba leków (Compound)	1552
Liczba skutków (Side Effect)	5734

3.2. Podział danych (link split)

Zgodnie z implementacją RandomLinkSplit

Parametr	Wartość
num_val	0.1
num_test	0.1
disjoint_train_ratio	0.3
Negatywy w treningu	neg_sampling_ratio=1.0

Parametr	Wartość
Typ krawędzi	wyłącznie ("Compound", "CcSE", "Side Effect")


Liczby par po podziale (RandomLinkSplit, seed=42):

Podział	Pozytywne CcSE (train)	Pary val	Pary test
Wartości	33 346 poz.	27 788 par	27 788 par

W podziale walidacyjnym i testowym liczba „par” obejmuje **pozytywne i negatywne** próbki linków CcSE (edge_label.numel() w loaderze). W treningu stosujemy neg_sampling_ratio=1.0 (261 batchy/epokę przy batch_size=128).

3.3. Ilustracja danych

Rysunek 1: fragment grafu Hetionet (BFS wokół przykładowej krawędzi; pełny graf jest zbyt gęsty do jednej ilustracji).



Fragment grafu Hetionet

Podgraf wyjaśnienia GNNExplainer - §7.3.

4. Architektura i implementacja

4.1. Model predykcyjny

Składnik	Opis	Plik
Encoder	2-warstwowy RGCN (HeteroConv + RGCNConv, agregacja mean → sum)	src/model.py
Embeddingi węzłów	nn.Embedding per typ węzła	src/model.py
Decoder	DistMult - iloczyn skalarny z wektorem relacji	src/model.py
Funkcja straty	binary_cross_entropy_with_logits	src/train_utils.py
Inferencja minibatch	LinkNeighborLoader	src/train_utils.py

4.2. Moduł XAI

Element	Opis
Algorytm	GNNExplainer (PyG Explainer)
Wrapper	CcSEExplainerWrapper - regresja na krawędzi CcSE
Podgraf	ten sam num_neighbors co w treningu
Ranking	top_k krawędzi wg edge_mask
Fidelity	spadek score po zamaskowaniu top-k ważnych krawędzi
Wyjście	outputs/explanation_gnn.png, logi W&B (job_type=explain)

5. Eksperymenty

5.1. Trening

- **Środowisko:** klaster Athena, Linux, Python 3.11, PyTorch 2.11 + CUDA 12.8, GPU **NVIDIA A100-SXM4-40GB**.
- **Siatka hiperparametrów** (scripts/slurm/train_grid.sh): wymiary embeddingu {64, 256, 512}, batch {128, 256}, lr {1e-2, 1e-3, 1e-4}, weight decay {1e-6, 1e-5}, sąsiedztwo {15 10, 20 15, 10 5} - łącznie **144 runy**.
- **Kryterium wyboru modelu:** najwyższa **best_val_ap** na zbiorze walidacyjnym.
- **Metryki raportowane:** AUC-ROC, AP (val i test po wczytaniu najlepszego checkpointu).
- **Run referencyjny (najlepszy run siatki):** grid-2654489_4_bs128_dim64_lr1e-2_wd1e-5_nh15-10 (W&B r4nyt104) - czas **4 min 25 s**.

5.2. Wyjaśnienia (XAI)

Dla każdej analizowanej pary (Compound, Side Effect):

Parametr	Wartość w eksperymencie
Podział (--split)	test
explainer_epochs	100
top_k	15

Przypadki do omówienia jakościowo:

#	Lek (nazwa / ID)	Skutek uboczny	Split
1	DB08887 (compound=1483)	C0015230 (side_effect=510)	test
2	DB00402 (compound=280)	C0003467 (side_effect=98)	test

6. Wyniki treningu

6.1. Najlepszy run siatki - wykres uczenia (W&B r4nyt104)

Run z **najwyższym best_val_ap** w siatce 144 konfiguracji. Checkpoint: grid_2654489_4_bs128_dim64_lr1e-2_wd1e-5_nh15-10.pth.

Hiperparametry: batch_size=128, embed_dim=64, lr=1e-2, weight_decay=1e-5, num_neighbors=[15, 10], epochs=50, patience=10, seed=42.

Metryki predykcji (checkpoint z epoki 11; test po wczytaniu najlepszego modelu):

Metryka	Walidacja (najlepsza epoka)	Walidacja (checkpoint wczytany po treningu)	Test
AUC-ROC	0,9532	0,9532	0,9528
AP	0,9498	0,9492	0,9485

Parametry przebiegu treningu:

Parametr	Wartość
Epoka najlepszego checkpointu	11
Early stopping	tak - brak poprawy val AP przez 10 epok (zatrzymano w epoce 21)
Czas treningu	4 min 25 s
Urządzenie	CUDA, NVIDIA A100-SXM4-40GB (węzeł t0014)

Krzywe uczenia (W&B, run r4nyt104):



Krzywe uczenia: train_loss, val_auc, val_ap

Model szybko zbiega (val AUC/AP rosną głównie w epokach 1-11). Końcowy `train_loss` = 0,218. Metryki testowe są bliskie walidacyjnym (różnica AP < 0,002).

6.2. Siatka hiperparametrów

Pełna siatka obejmuje 144 runy. Poniżej **4 runy z najwyższym `best_val_ap`** oraz wybrany run z niższym `lr` (`1e-3`) do porównania.

Run (tag)	bs	dim	lr	wd	neighbors	Best Val AP	Best Val AUC	Test AP	Test AUC	Uwagi
grid-2654489_4_... _lr1e-2_... _nh15-10	128	64	1e-2	1e-5	15, 10	0,9498	0,9532	0,9485	0,9528	najlepszy - run z §6.1, W&B r4nyt104
grid-2654489_5_... _lr1e-2_... _nh20-15	128	64	1e-2	1e-5	20, 15	0,9497	0,9528	0,9461	0,9507	
grid-2654493_11_... _dim128_lr1e-3_...	128	128	1e-3	1e-5	20, 15	0,9494	0,9494	0,9462	0,9468	większy <code>embed_dim</code> , niższy test AUC
grid-2654489_6_... _lr1e-2_... _nh10-5	128	64	1e-2	1e-5	10, 5	0,9493	0,9509	0,9486	0,9508	mniejsze sąsiedztwo
grid-2654489_10_... _lr1e-3_... _nh15-10	128	64	1e-3	1e-5	15, 10	0,9487	0,9503	0,9478	0,9501	porównawczy: ten sam układ hiperparametrów, <code>lr=1e-3</code> (W&B f78fxjqw)
grid-2654496_4_... _dim512_lr1e-2_...	128	512	1e-2	1e-5	15, 10	0,6909	0,7273	0,6928	0,7244	najniższe <code>best_val_ap</code> w siatce

6.3. Analiza wyników predykcji

W siatce najlepsze runy osiągają test AP/AUC $\approx 0,95$ przy `embed_dim` 64-128; najgorszy run (`embed_dim`=512, ten sam `lr` i sąsiedztwo) ma test AP $\approx 0,693$ i test AUC $\approx 0,724$ - nadal powyżej losowego (0,5), ale wyraźnie poniżej najlepszych konfiguracji.

Wnioski (trening): RGCN + DistMult na Hetionet z neighbor sampling osiąga test AP/AUC $\approx$ **0,948 / 0,953** (najlepszy run §6.1). Najlepsza konfiguracja: `embed_dim`=64, `lr`=1e-2, batch 128. Trening trwa kilka minut na A100 (np. 4,5 min dla runu referencyjnego). Metryki testowe są bliskie walidacyjnym.

7. Wyniki interpretowalności (XAI)

7.1. Metryki ilościowe XAI

#	Para (lek → skutek)	Score	Score po mask. top-k	Fidelity Δ	Węzły	Krawędzie
1	DB08887 → C0015230	3,621	2,997	0,624	88	90
2	DB00402 → C0003467	6,323	2,700	3,623	82	86

7.2. Top-k krawędzi

7.2.1. DB08887 → C0015230


Rank	Waga	Typ źr.	Relacja	Typ celu	Źródło (ID)	Cel (ID)
1	0,837	Compound	CrC	Compound	GO:0003184	GO:0002328
2	0,817	Compound	CrC	Compound	UBERON:0000995	UBERON:0000989
3	0,814	Pharmacologic Class	PCiC	Compound	UBERON:0001647	GO:0002328
4	0,814	Compound	CcSE	Side Effect	GO:0002460	GO:0000491
5	0,805	Pharmacologic Class	PCiC	Compound	UBERON:0000473	GO:0003416
6	0,800	Compound	CcSE	Side Effect	GO:0002589	GO:0000491
7	0,798	Compound	CrC	Compound	GO:0002005	GO:0002068
8	0,797	Pharmacologic Class	PCiC	Compound	UBERON:0001890	GO:0006029
9	0,794	Compound	CrC	Compound	UBERON:0002066	GO:0003430
10	0,787	Pharmacologic Class	PCiC	Compound	UBERON:0001225	GO:0002589
11	0,786	Pharmacologic Class	PCiC	Compound	UBERON:0001986	GO:0000018
12	0,782	Compound	CrC	Compound	UBERON:0000473	UBERON:0000995
13	0,776	Compound	CrC	Compound	GO:0003018	GO:0006203
14	0,772	Compound	CrC	Compound	GO:0002125	GO:0006203
15	0,765	Compound	CcSE	Side Effect	GO:0003408	GO:0000491

W top-15 dominują relacje CrC, PCiC, oraz CcSE.

7.2.2. DB00402 → C0003467

Rank	Waga	Typ źr.	Relacja	Typ celu	Źródło (ID)	Cel (ID)
1	0,828	Compound	CrC	Compound	UBERON:0004288	GO:0002477
2	0,823	Compound	CrC	Compound	GO:0002883	UBERON:0001681
3	0,812	Compound	CrC	Compound	GO:0006056	UBERON:0001681

Przypadek 2 - DB00402 → C0003467 (W&B d1x13eu1; score 6,32; fidelity 3,62):



Wyjaśnienie DB00402 → C0003467

Na obu wykresach widać 15 ważnych krawędzi, węzeł leku, węzeł skutku (pomarańczowy) oraz pośrednie węzły. Szare węzły odpowiadają klasom farmakologicznym (PCiC).

7.4. Ocena jakościowa

GNNExplainer nadaje wagi **każdej** krawędzi podgrafu z neighbor loadera (86-90 krawędzi, §7.1). W raporcie pokazujemy **15 krawędzi z najwyższymi wagami** - parametr top_k=15 to **próg wizualizacji**.

Czy wybrane krawędzie mają znaczenie dla modelu, sprawdzamy **fidelity**: o ile spada score predykcji po ich zamaskowaniu. W obu parach fidelity > 0 (§7.1).

	DB08887 → C0015230	DB00402 → C0003467
Krawędzie w podgrafie	90	86
Fidelity	0,624	3,623
Główne typy relacji w top-k	CrC, PCiC, CcSE	CrC, PCiC

Wizualizacje (§7.3) są czytelne - węzeł leku, skutku i pośrednie węzły połączone w krótkich ścieżkach. Fidelity różni się między parami (0,62 vs 3,62), więc ranking krawędzi zależy od konkretnej pary lek-skutek.

Wnioski (XAI): Explainer rankinguje ok. 90 krawędzi; top-15 to skrót do prezentacji. Dodatnia fidelity uzasadnia, że te krawędzie wpływają na predykcję modelu. **H2 - TAK** (zwięzłe wyjaśnienia w §7.3, potwierdzone fidelity).

8. Ograniczenia i ryzyka (aktualizacja)

Ryzyko (wstępne)	Obserwacja po implementacji
Zużycie VRAM na pełnym grafie	Rozwiązane - LinkNeighborLoader + num_neighbors umożliwiły trening na A100 w kilku minutach na konfigurację
Niestabilność GNNExplainer	Różne fidelity między parami (np. 0,62 vs 3,62 przy tym samym top_k) - wrażliwość na parę lek-skutek
Rozbieżność split train/test w XAI	Wyjaśnienia używają tego samego RandomLinkSplit i seed co trening
Brak MRR	Ranking globalny nie był celem minimalnej implementacji

Inne ograniczenia: jedna warstwa RGCN i jeden algorytm XAI (GNNExplainer); brak walidacji klinicznej wyjaśnień; duża zmienność fidelity między parami przy stałym top_k.

9. Wyniki

1. Model RGCN osiągnął na zbiorze testowym **AP = 0,948** i **AUC = 0,953** dla relacji CcSE (najlepszy run siatki hiperparametrów).
 2. GNNExplainer: maskowanie top-15 krawędzi obniża score w obu parach (fidelity **0,62** i **3,62**).
 3. **H1 (potwierdzona):** po zmianie relacji docelowej z **CtD** na **CcSE** RGCN osiąga AP/AUC $\approx 0,95$ - model wykorzystuje heterogeniczne typy krawędzi Hetionet do predykcji skutków ubocznych.
 4. **H2 (potwierdzona):** explainer rankinguje pełny podgraf (~90 krawędzi); top-15 + dodatnia fidelity dają zwarte, wierne modelowi wyjaśnienia.
-

10. Wnioski końcowe

Projekt zrealizował pełny pipeline: preprocessing Hetionet, trening RGCN + DistMult na relacji CcSE, siatkę hiperparametrów na klastrze oraz interpretację wybranych predykcji przez GNNExplainer z logowaniem do W&B.

Predykcja. Po zmianie zadania z CtD na CcSE model osiągnął test AP/AUC ok. **0,95** - RGCN wykorzystuje heterogeniczną strukturę grafu (24 typy relacji) do przewidywania skutków ubocznych. Siatka 144 runów pokazała, że wystarczają umiarkowane embeddingi (64-128) i neighbor sampling; konfiguracja z embed_dim=512 przy tym samym lr wyraźnie gorsza (~0,69 AP), co warto mieć na uwadze przy dalszym tuningu.

Interpretowalność. Dla dwóch par testowych (DB08887 → C0015230, DB00402 → C0003467) explainer nadał wagi wszystkim krawędziom podgrafu (~86-90), a w raporcie pokazaliśmy top-15. Dodatnia **fidelity** w obu przypadkach oznacza, że wybrane krawędzie wpływają na score modelu - wyjaśnienie jest wierne modelowi,

nie tylko krótkie. Wizualizacje (§7.3) są czytelne; skład top-k różni się między parami (np. obecność krawędzi CcSE u pierwszej pary, dominacja CrC/PCiC u drugiej).

Hipotezy. H1 - TAK w zakresie przyjętego zadania (predykcja CcSE na pełnym Hetionet). **H2 - TAK** - zwięzła prezentacja wyjaśnień i potwierdzenie przez fidelity; nie ocenialiśmy klinicznej poprawności ścieżek przez eksperta medycznego.

Ograniczenia i dalsza praca. Wyjaśnienia zależą od top_k i są wrażliwe na parę lek-skutek (fidelity 0,62 vs 3,62). Naturalnym rozszerzeniem byłaby walidacja przez eksperta, mapowanie ID ontologii na nazwy oraz test innych algorytmów XAI.

11. Bibliografia

1. Schlichtkrull, M., et al. (2018). *Modeling Relational Data with Graph Convolutional Networks*. ESWC.
2. Ying, R., et al. (2019). *GNNExplainer: Generating Explanations for Graph Neural Networks*. NeurIPS.
3. Himmelstein, D. S., et al. (2017). *Systematic integration of biomedical knowledge prioritizes drugs for repurposing*. eLife. (Hetionet)
4. Wójcik, F. *Grafowe sieci neuronowe*.
5. Kuhn, M., et al. (2016). *The SIDER database of drugs and side effects*. Nucleic Acids Research. (źródło relacji CcSE w Hetionet)